

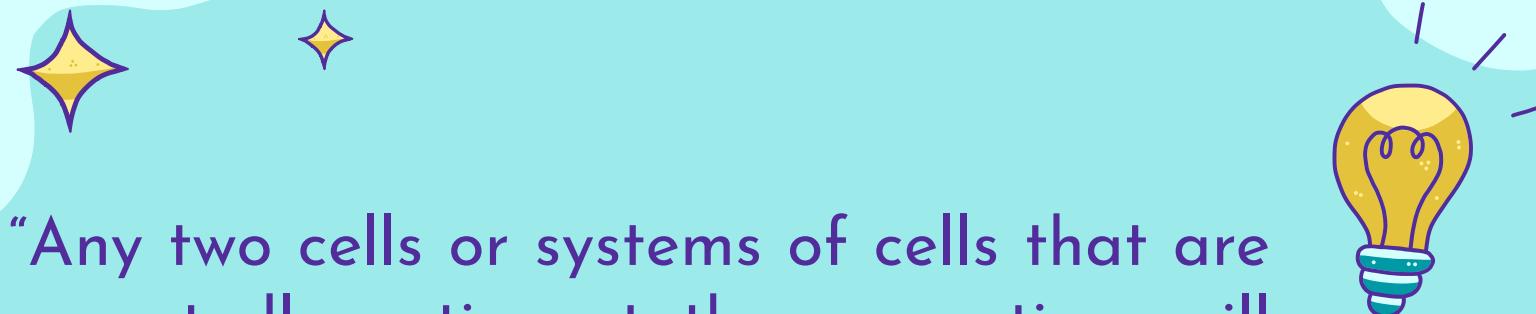


Perceptrón Simple y Multicapa

Sistemas de Inteligencia Artificial 2C-2022
Grupo 1 - "Augusta Ada King"

Domingues Paula
Donikian Gastón
Pavan Matias
Rodriguez Manuel

60148
60067
58296
60258



“Any two cells or systems of cells that are repeatedly active at the same time will tend to become ‘associated,’ so that activity in one facilitates activity in the other”

–Donald O. Hebb





01

Perceptrón Simple

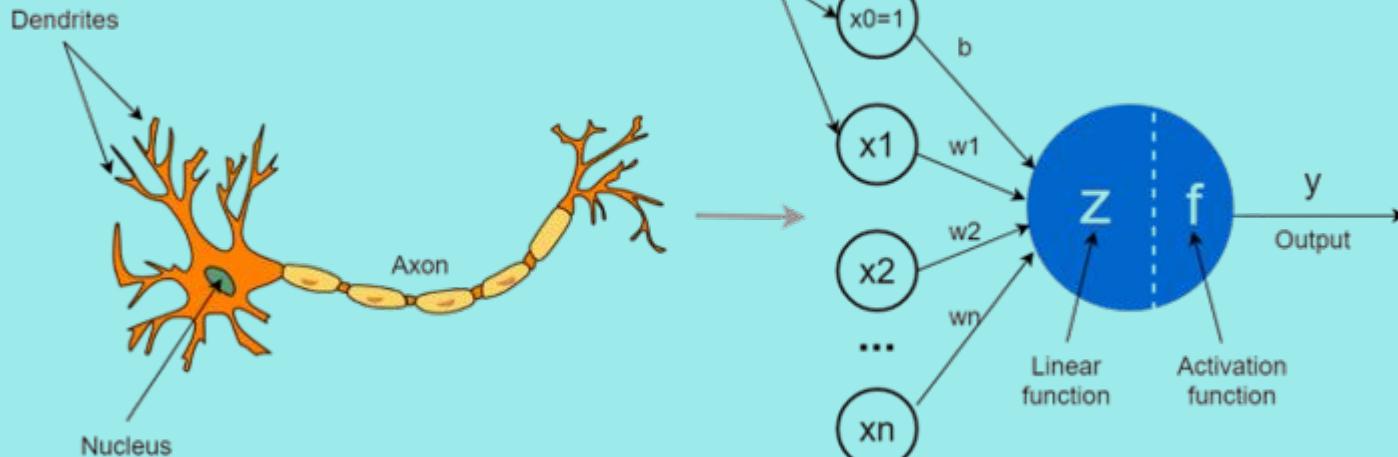
02

Perceptrón multicapa

01

Perceptrón Simple

Introducción



Ejercicio 1

Evaluación de perceptrón
simple escalonado



Perceptrón Simple

Datos de entrada

AND

A	B	Esperado
-1	1	-1
1	-1	-1
1	1	1
-1	-1	-1

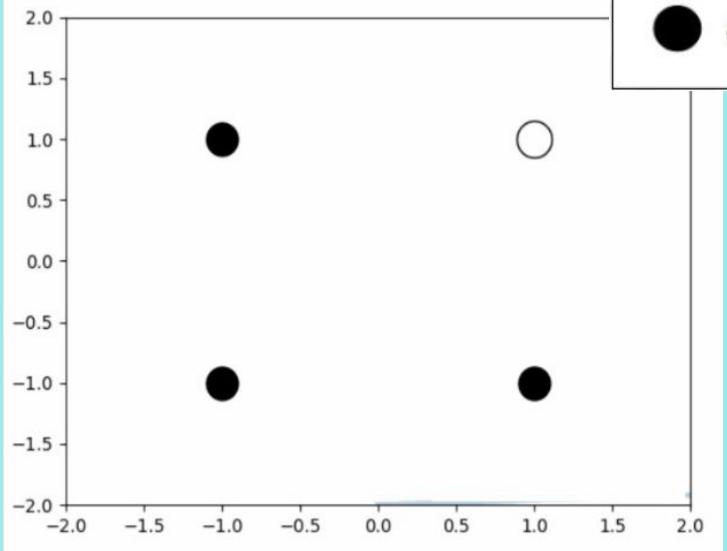
XOR

A	B	Esperado
-1	1	1
1	-1	1
1	1	-1
-1	-1	-1

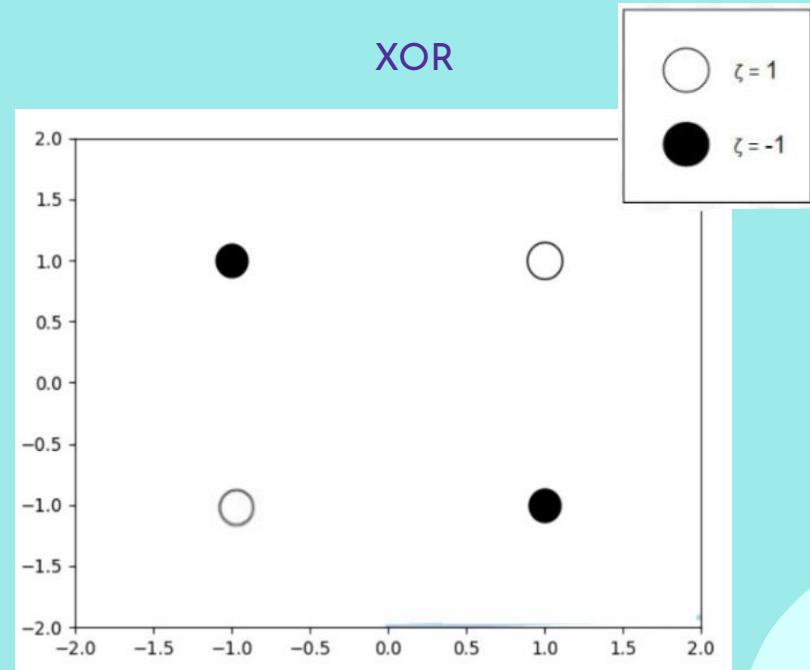
Perceptrón Simple

Datos de entrada

AND



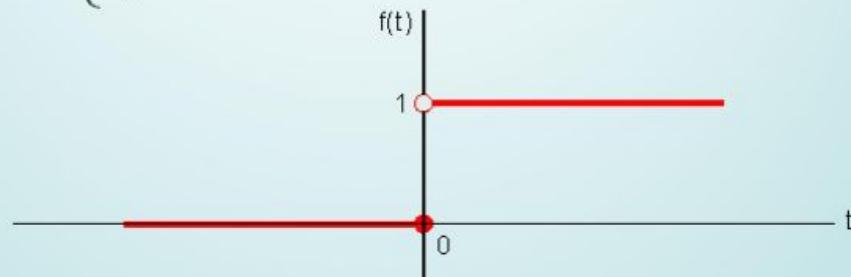
XOR



Perceptrón Simple

Función de activación - Escalón

$$U(t) = \begin{cases} 0, & t \leq 0 \\ 1, & t > 0 \end{cases}$$



$$O = U(\sum_{i=1}^n w_i \xi_i - \text{umbral})$$

Queremos que

O^u sea igual a ζ^u donde
 ζ es el valor esperado para ξ

Perceptrón Simple

Aprendizaje del Perceptrón

$$\mathbf{w}_i^{nuevo} = \mathbf{w}_i^{viejo} + \Delta \mathbf{w}_i$$

$$\Delta \mathbf{w}_i = \eta (\zeta^u - O^u) \xi_u^i$$

η es la tasa de aprendizaje

$(\zeta^u - O^u)$ es el error asociado

ξ_u^i es la entrada asociada

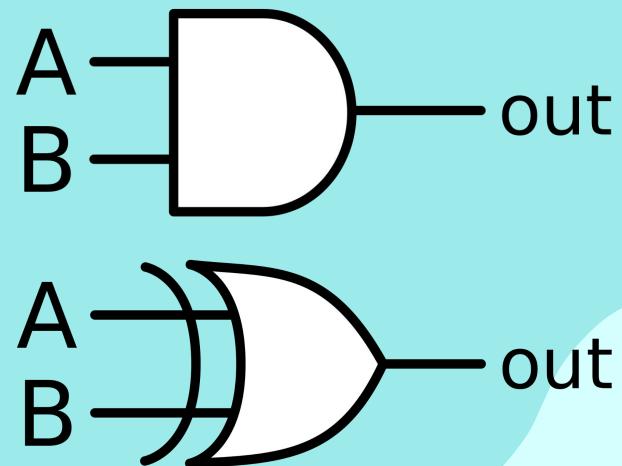
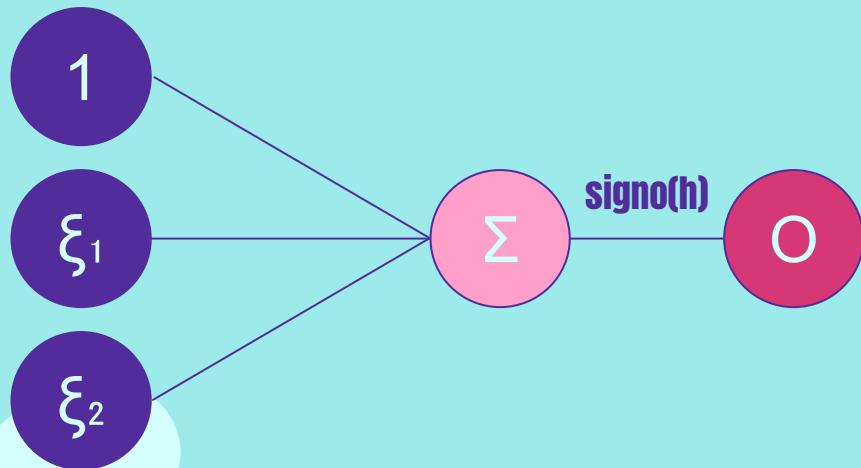
Queremos encontrar los w que minimicen:

$$E(w) = \frac{1}{p} \sum_{u=1}^p (\zeta^u - O^u)^2$$

Función de error del perceptron

Perceptrón Simple

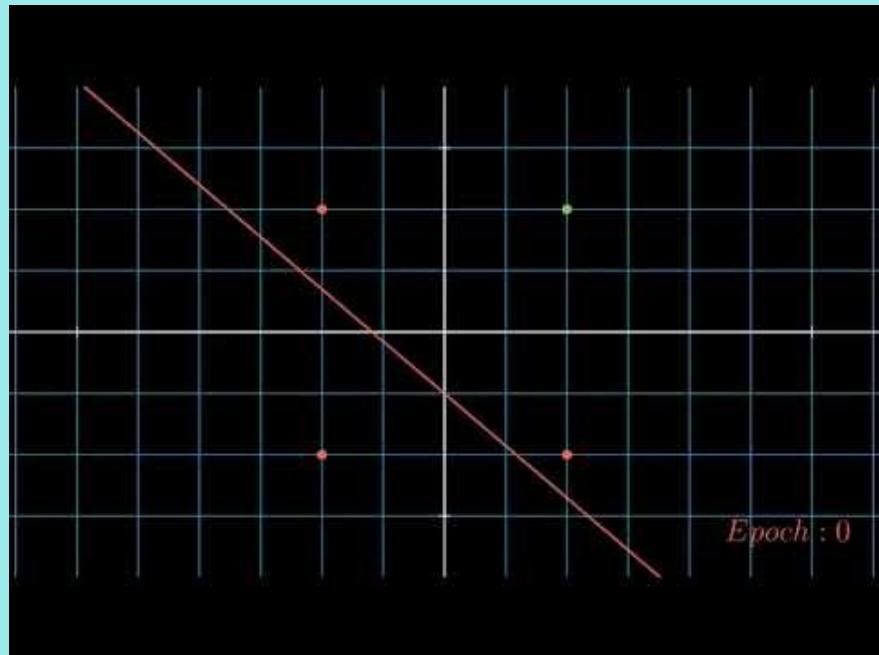
Perceptrón escalón contra dataset AND y XOR



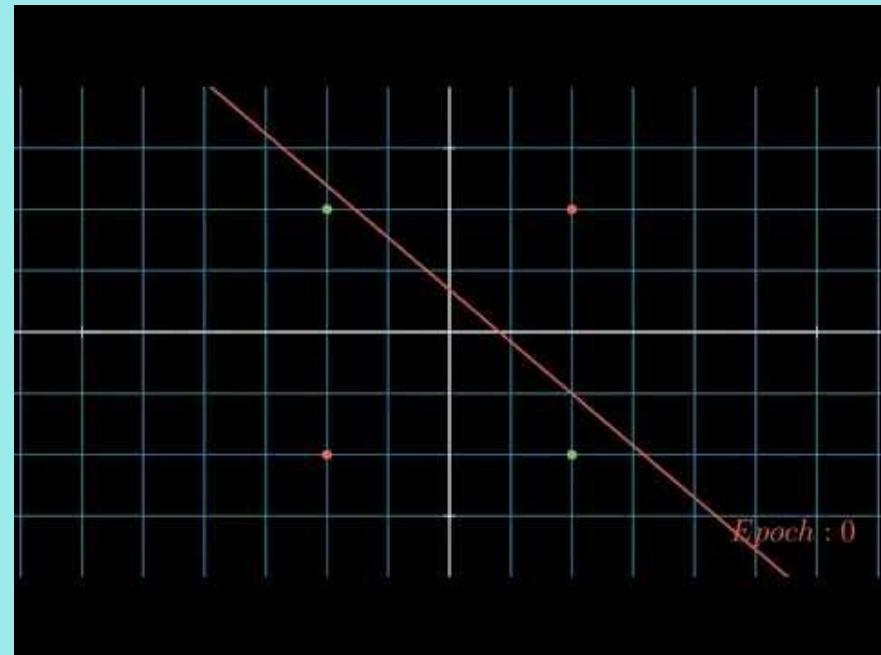
Perceptrón Simple

Resultados

AND



XOR



Parámetros: $n = 0.01$, $F = \text{SIGNO}$

**¿Qué puede decir acerca de los problemas que
puede resolver el perceptrón simple escalón
en relación a los problemas planteados en la
consigna?**

Ejercicio 2

Evaluación de perceptrón
simple lineal y no lineal



Perceptrón Simple

Datos de entrada

$$\xi = (\xi_1, \xi_2, \xi_3) =$$

1.200	-0.800	0.000
1.200	0.000	-0.800
1.200	-0.800	1.000
0.000	1.200	-0.800
7.900	1.000	0.000
0.400	0.000	2.700
0.000	0.400	2.700
-1.300	3.230	3.000
0.400	2.700	0.000
0.400	2.700	2.000
-1.300	0.000	3.230
0.000	-1.300	3.230
7.900	1.000	-2.000
1.800	0.000	1.600
0.000	-2.000	2.000
-0.500	0.600	0.000
0.000	1.800	1.600
-2.000	2.000	0.000
-0.500	0.600	2.500
7.900	0.000	1.000
-1.300	3.230	0.000
0.000	7.900	1.000
-2.000	0.000	2.000
-2.000	2.000	-1.000
0.000	-0.500	0.600
1.800	1.600	1.300
-0.500	0.000	0.600
1.800	1.600	0.000

$$\zeta =$$

21.755
7.176
43.045
2.875
26.503
68.568
61.301
23.183
2.820
17.654
72.512
88.184
4.653
49.000
76.852
7.871
18.543
2.660
51.000
64.107
1.480
0.320
40.131
0.995
24.974
21.417
18.243
6.914

Perceptrón Simple

Problema de estandarización y escalaje

Inputs se escalarizan o estandarizan según la función de activación.

Signo
Linear } Estandarización

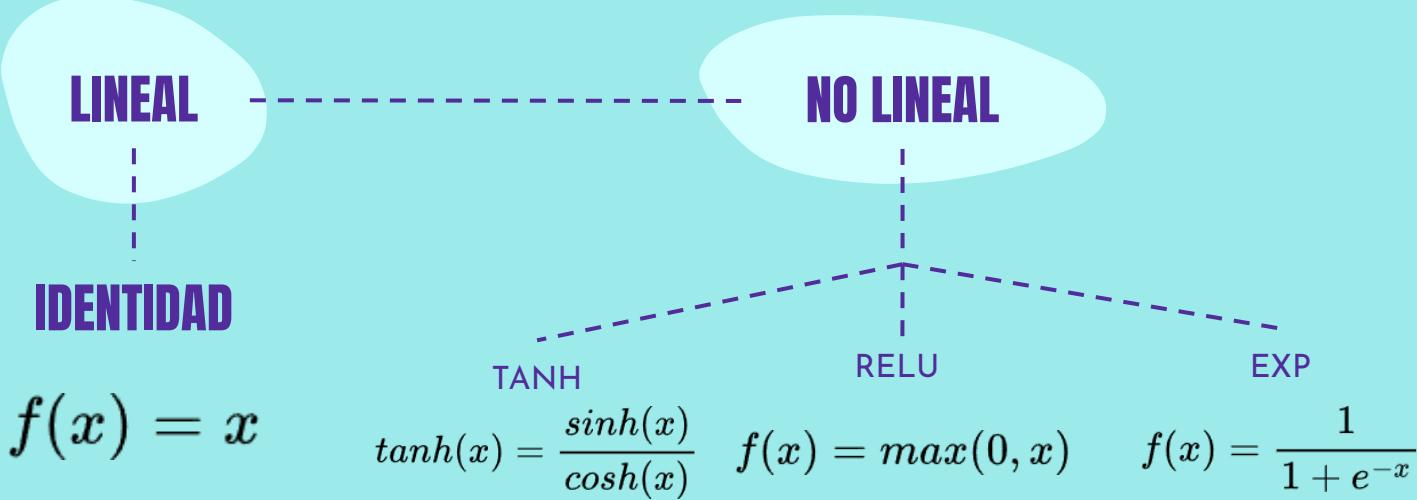
TANH } Escalarización en (-1,1)

EXP
RELU } Escalarización en (0,1)

Los outputs siempre se estandarizan para evitar perder la información que dan los outliers

Perceptrón Simple

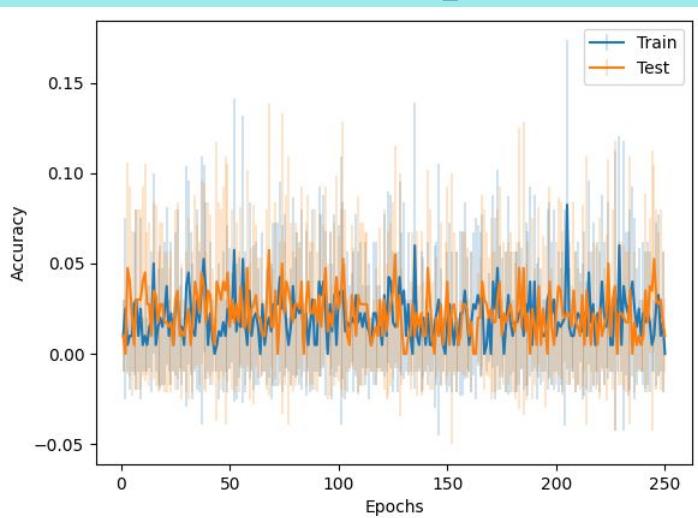
Funciones de activación



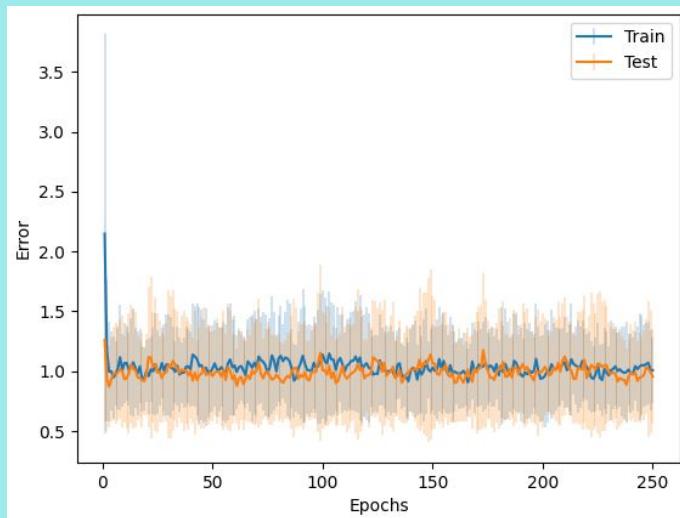
Perceptrón lineal Resultados

$$f(x) = x$$

Accuracy



Error



Parámetros:

$n = 0.05$

Epochs = 250

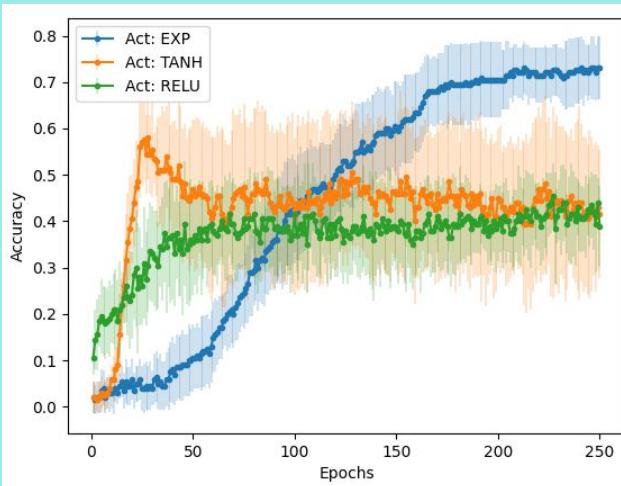
Porcentaje de
entrenamiento: 70%

Prediction threshold = 0.01

Perceptrón no lineal

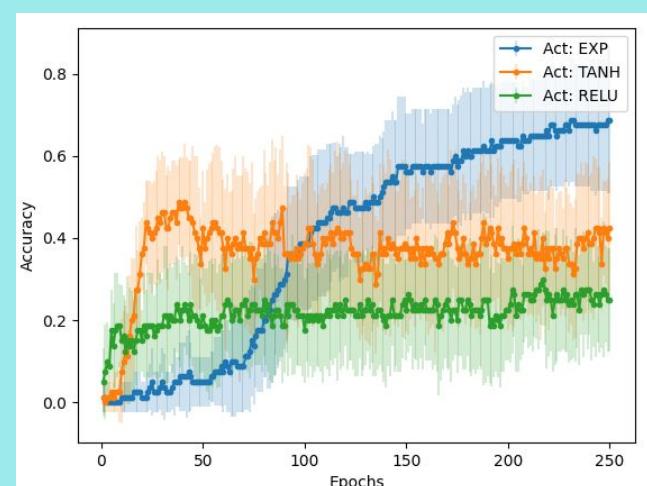
Resultados variando la función de activación

Training accuracy



Parámetros:
 $n = 0.05$
Epochs = 250
Beta = 1
Training online
Porcentaje de
entrenamiento: 70%
Prediction
Threshold = 0.01

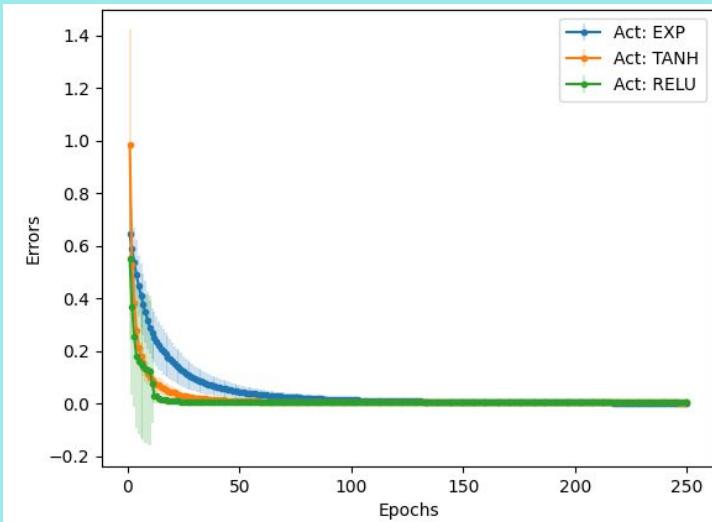
Test accuracy



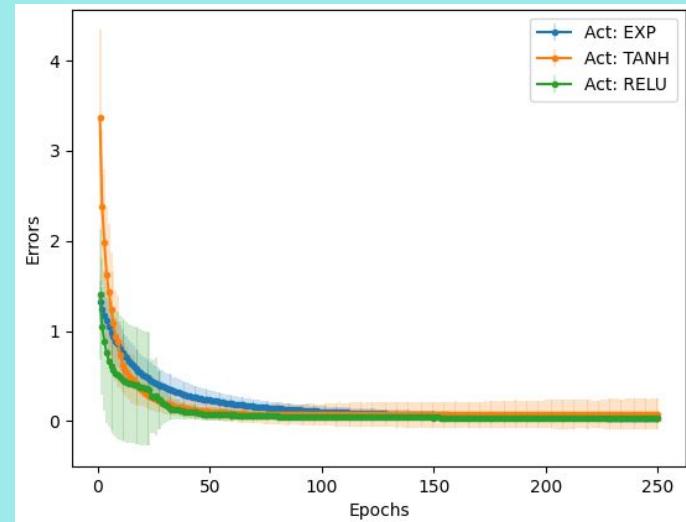
Perceptrón no lineal

Resultados variando la función de activación

Training error



Test error

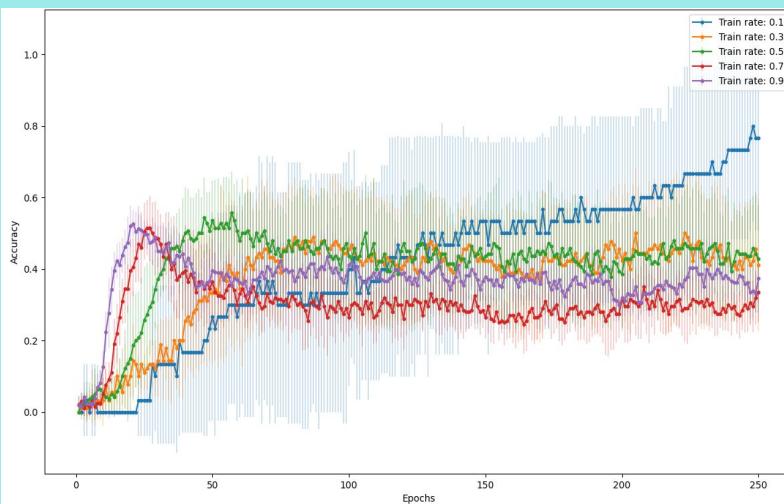


Parámetros:
n = 0.05
Epochs = 250
Beta = 1.0
Training online
Porcentaje de
entrenamiento: 70%
Prediction
threshold = 0.01

Perceptrón Simple

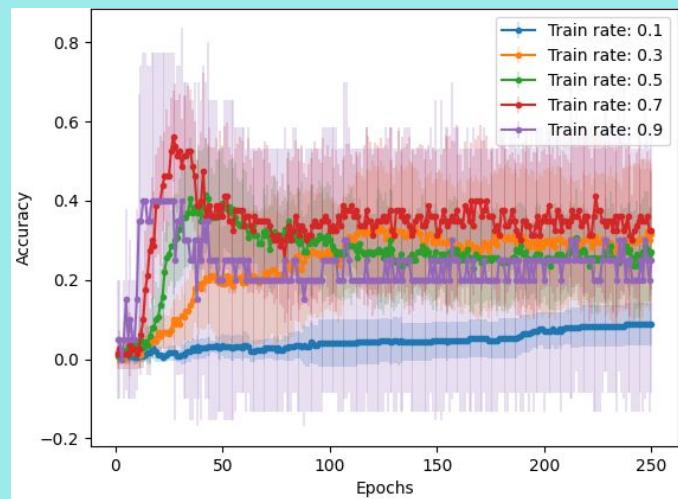
Resultados variando porcentaje de división

Training accuracy



Parámetros:
 $n = 0.05$
Epochs = 250
Beta = 1.0
Training online
 $F = \text{TANH}$
Prediction threshold = 0.1

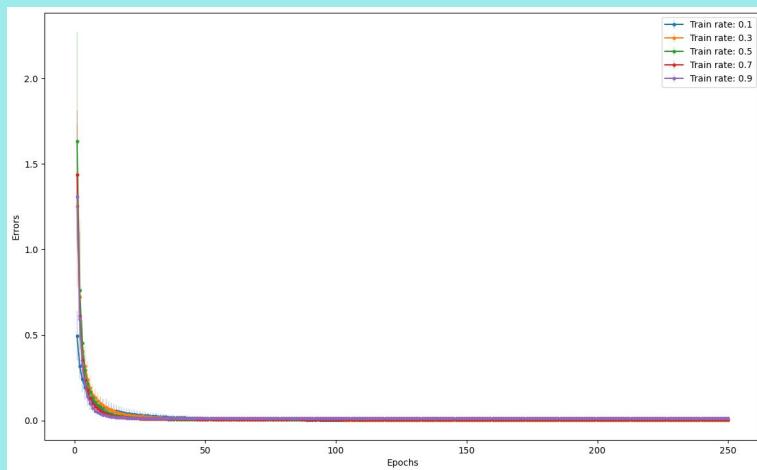
Test accuracy



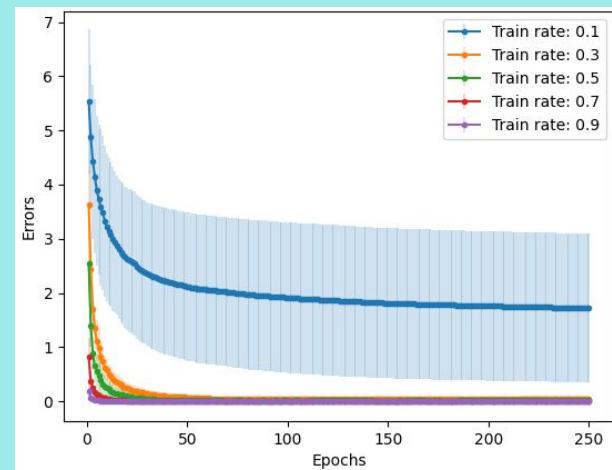
Perceptrón Simple

Resultados variando porcentaje de división

Training error



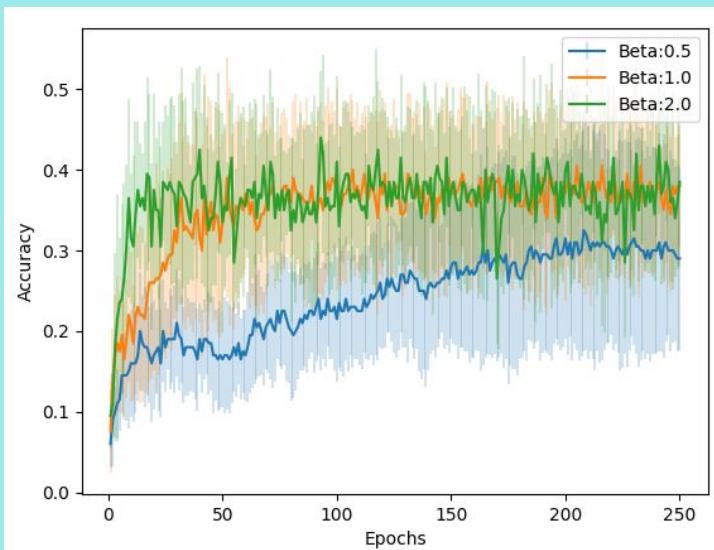
Test error



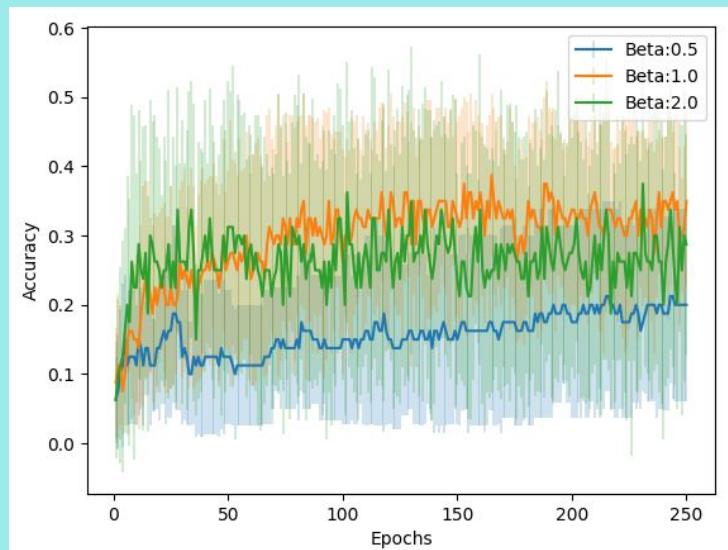
Perceptrón Simple

Resultados variando Beta (con RELU como F)

Training accuracy



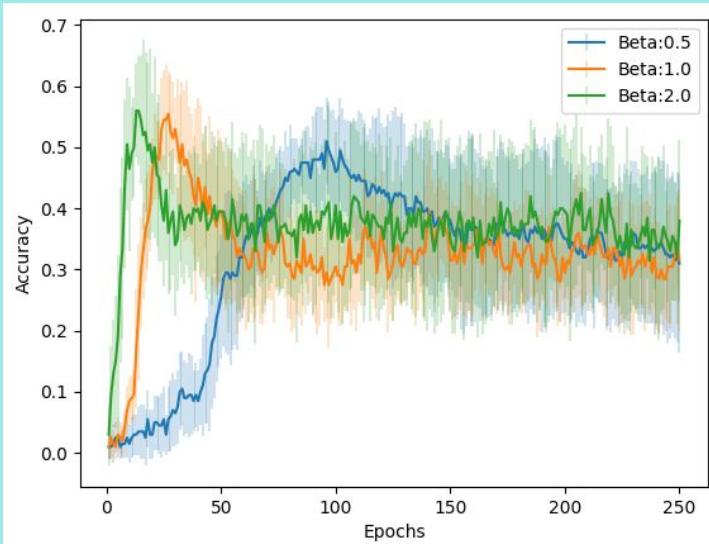
Test accuracy



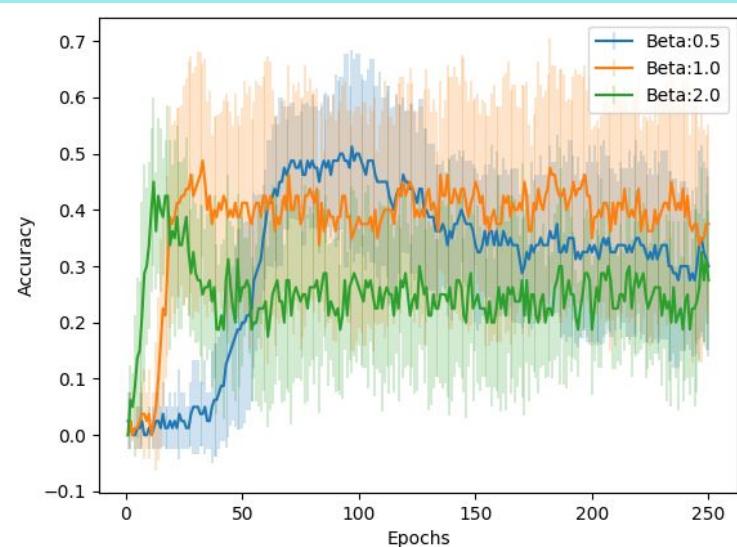
Perceptrón Simple

Resultados variando Beta (con tanh como F)

Training accuracy



Test accuracy

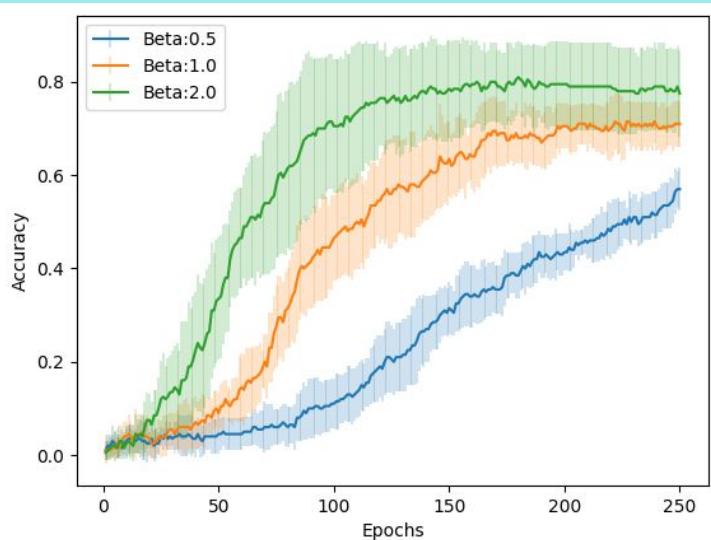


Parámetros:
 $n = 0.05$
Epochs = 250
 $F = \text{TANH}$
Training online
 $N = 10$
Porcentaje de
entrenamiento: 70%
Prediction
threshold = 0.01

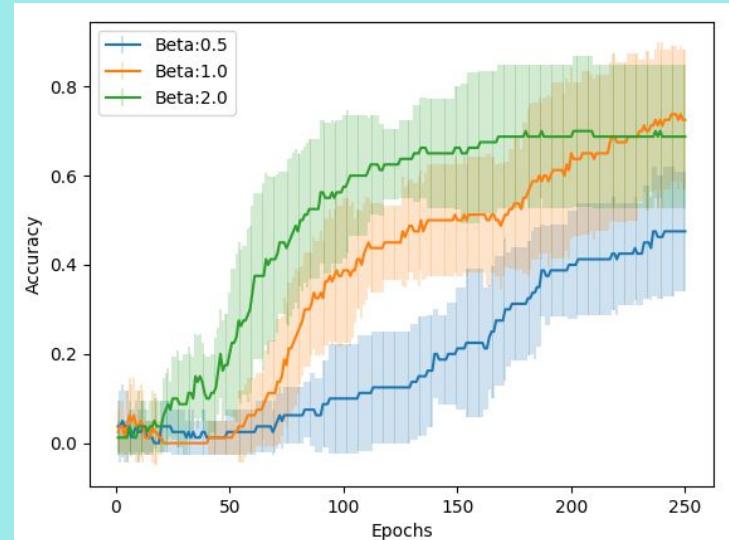
Perceptrón Simple

Resultados variando Beta (con exponencial como F)

Training accuracy



Test accuracy

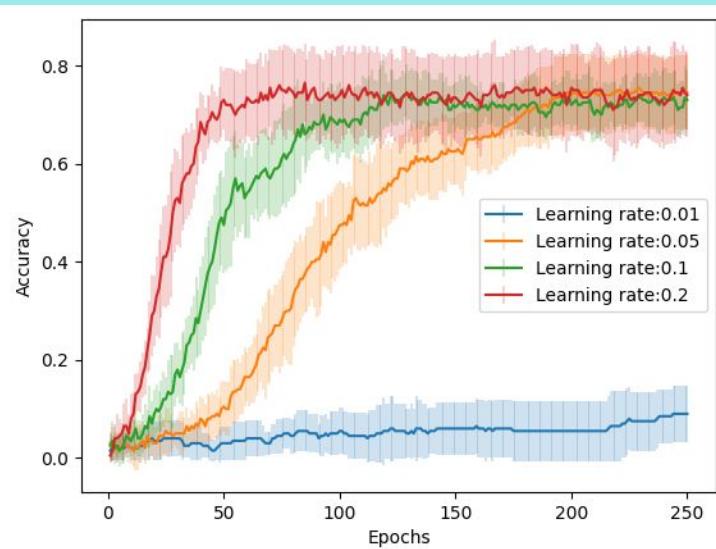


Parámetros:
 $n = 0.05$
Epochs = 250
 $F = \text{EXP}$
Training online
 $N = 10$
Porcentaje de
entrenamiento: 70%
Prediction
threshold = 0.01

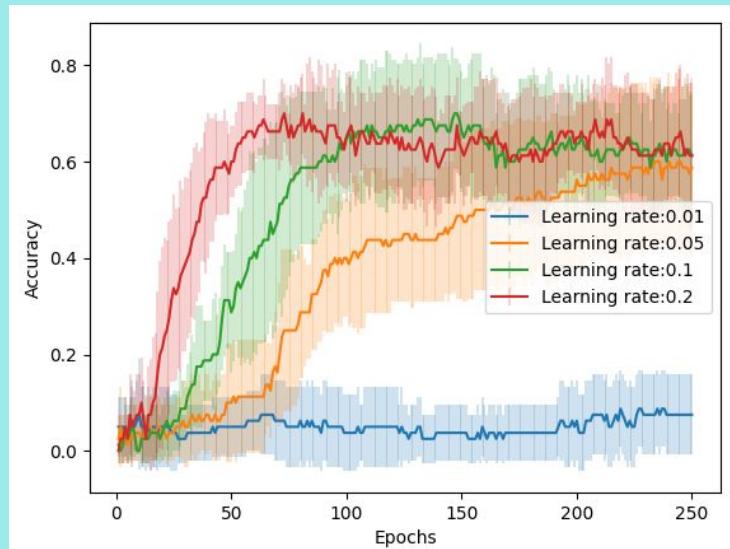
Perceptrón Simple

Resultados variando learning rate

Training accuracy



Test accuracy

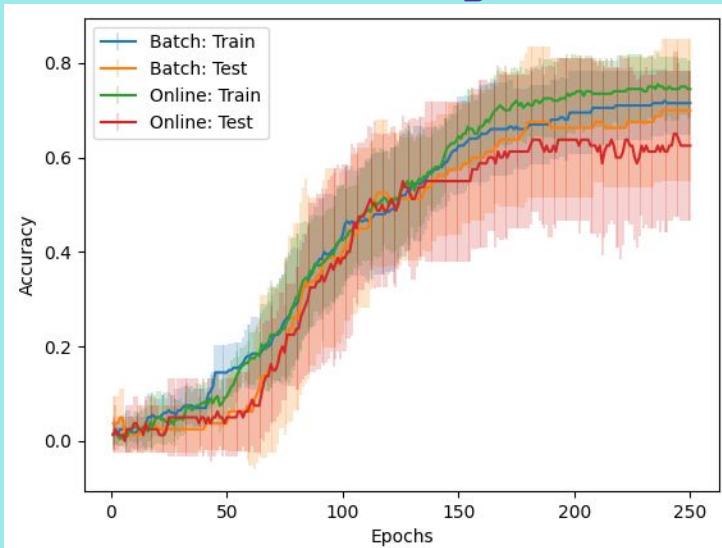


Perceptrón Simple

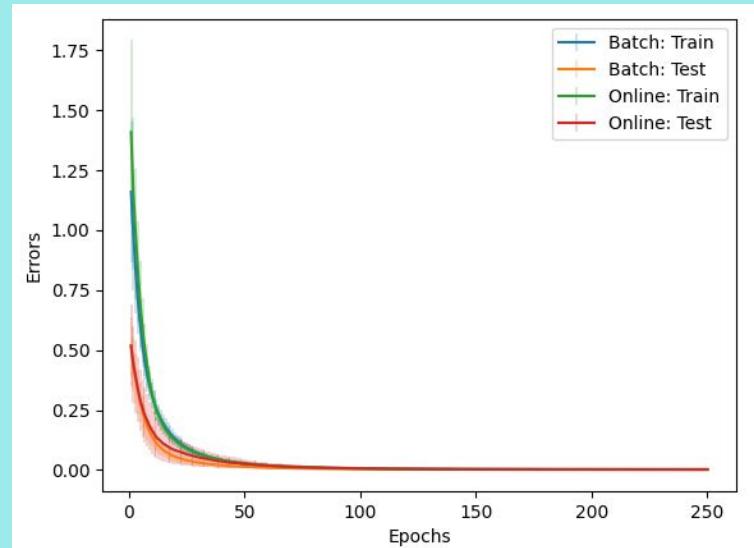
Resultados de Batch vs. Online

Parámetros:
 $n = 0.05$
Epochs = 250
Beta = 1.0
 $F = \text{EXP}$
 $N = 100$
Prediction threshold = 0.01
Porcentaje de entrenamiento: 70%

Accuracy



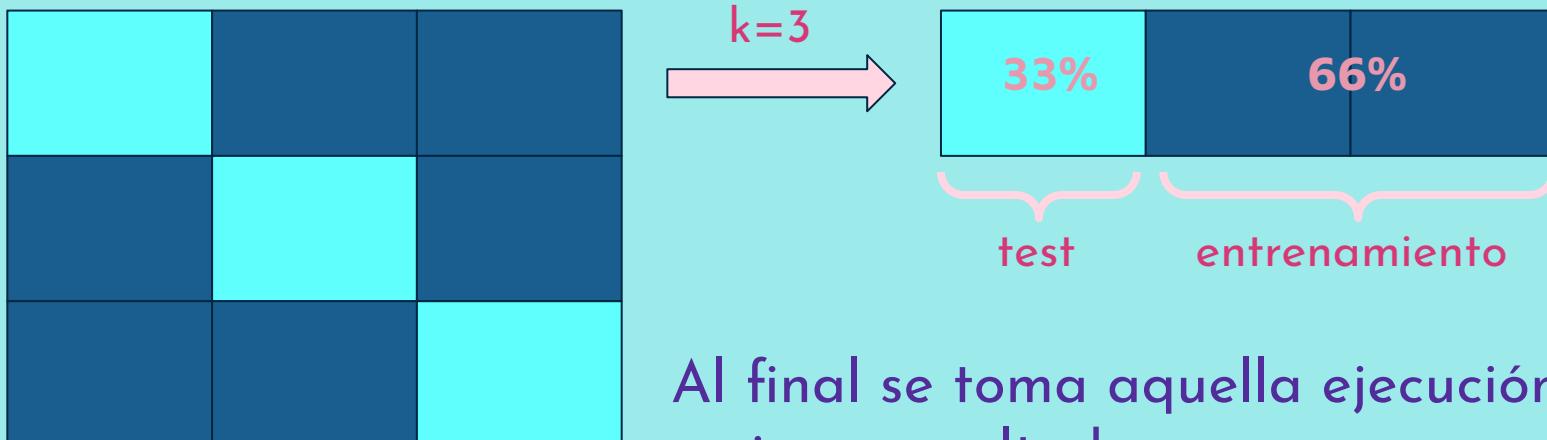
Error



Validación cruzada

Definición

Se parte el dataset en K partes, se ejecuta K veces el entrenamiento variando el dataset de entrenamiento y el de testeo.

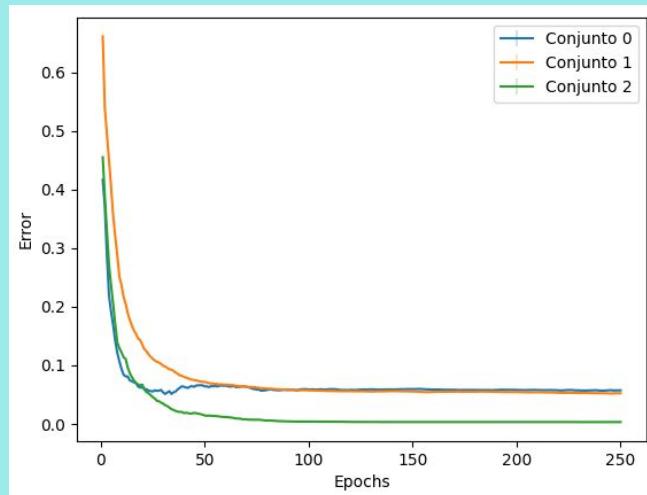


Al final se toma aquella ejecución con mejores resultados.

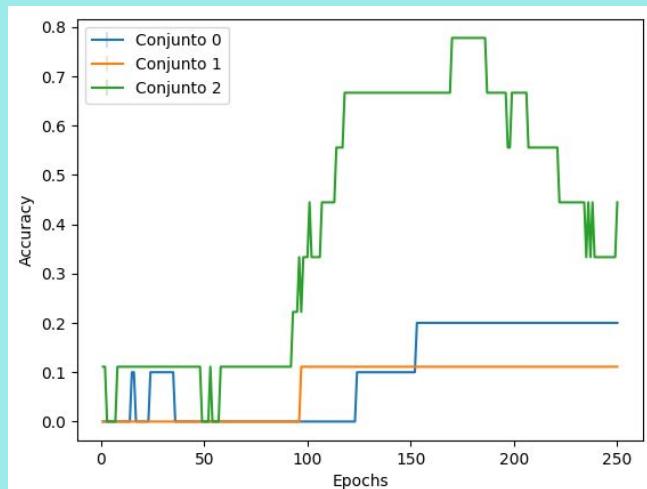
Validación cruzada

Resultados

Train accuracy



Test accuracy



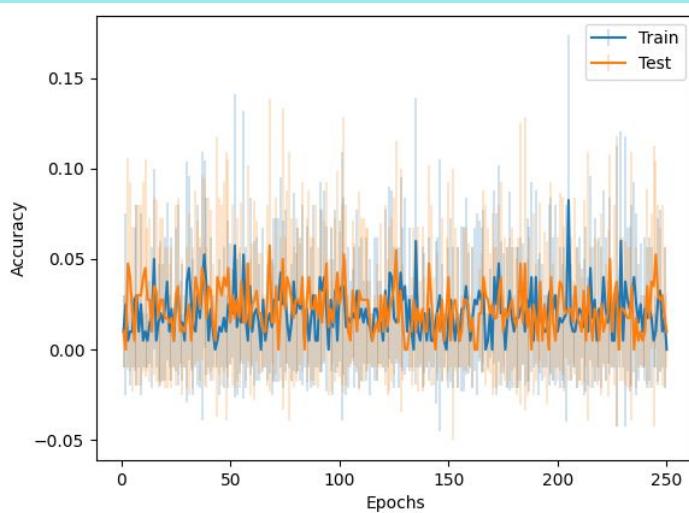
Parámetros:
 $K = 5$
 $n = 0.05$
 $\text{Epochs} = 250$
 $\text{Beta} = 1$
 $F = \text{EXP}$
Training online
Prediction threshold = 0.01

Vemos que tomar el conjunto 2 como testeo fue lo que dio la mejor performance.

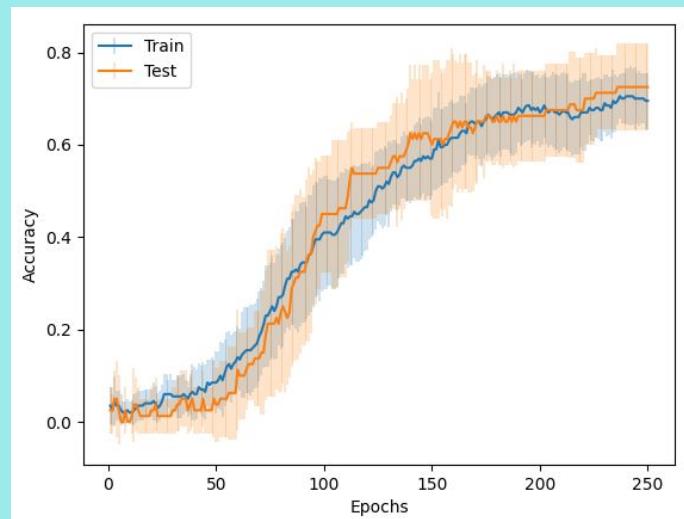
Perceptrón lineal vs no lineal

Comparación de resultados

Lineal



No Lineal

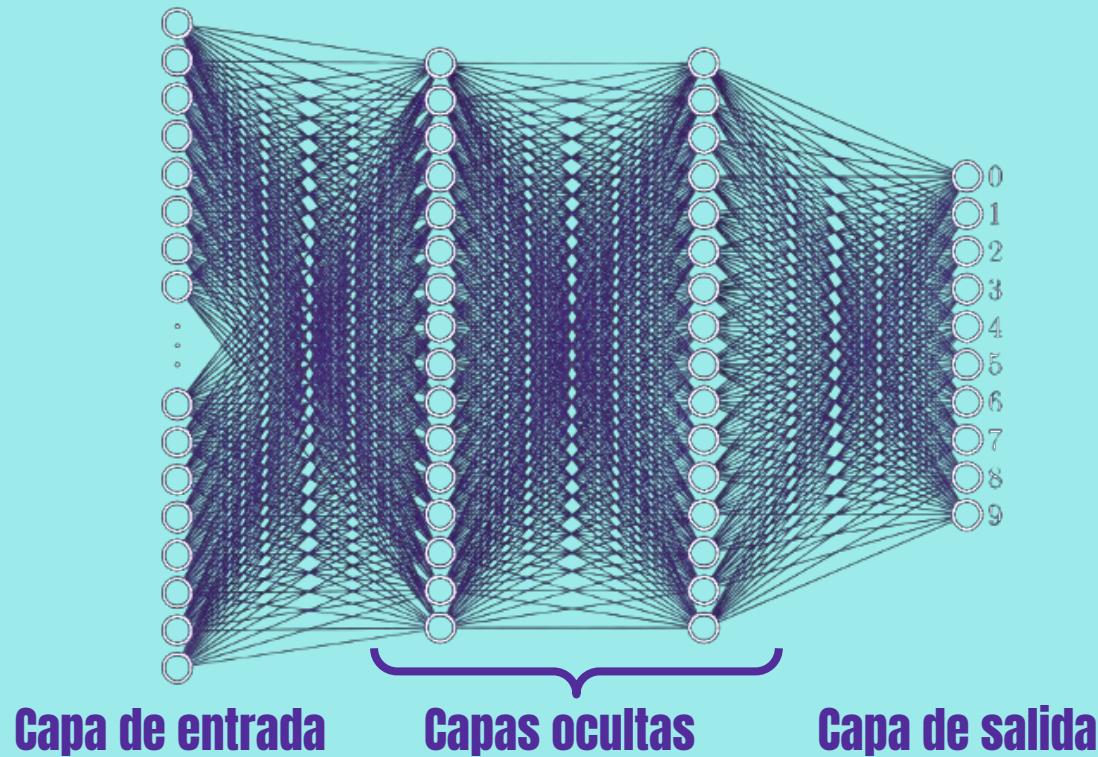


02

Perceptrón Multicapa

Perceptrón Multicapa

Arquitectura



Ejercicio 3.1

“O exclusivo”



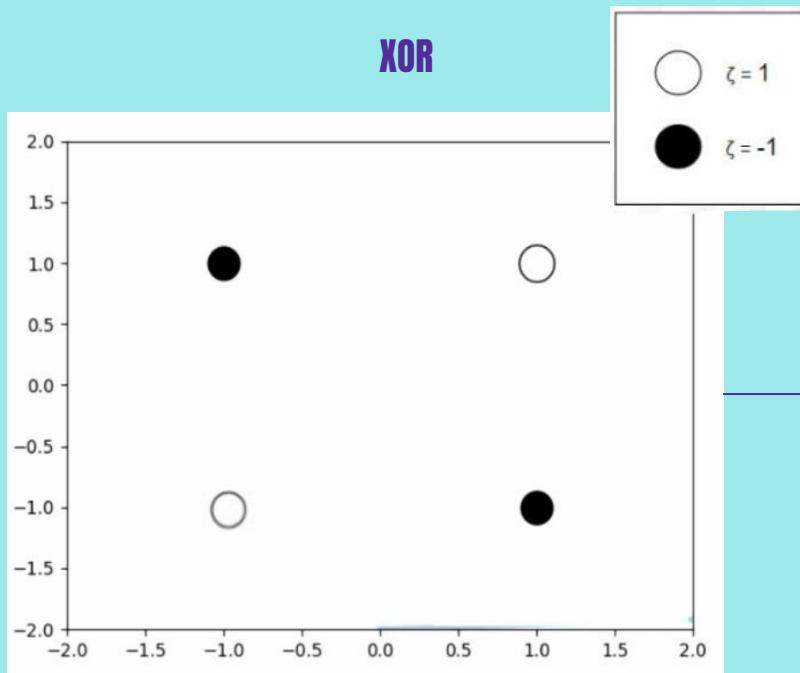
Ejercicio 3.1

Datos de entrada

Funcion logica “O exclusivo” (XOR)

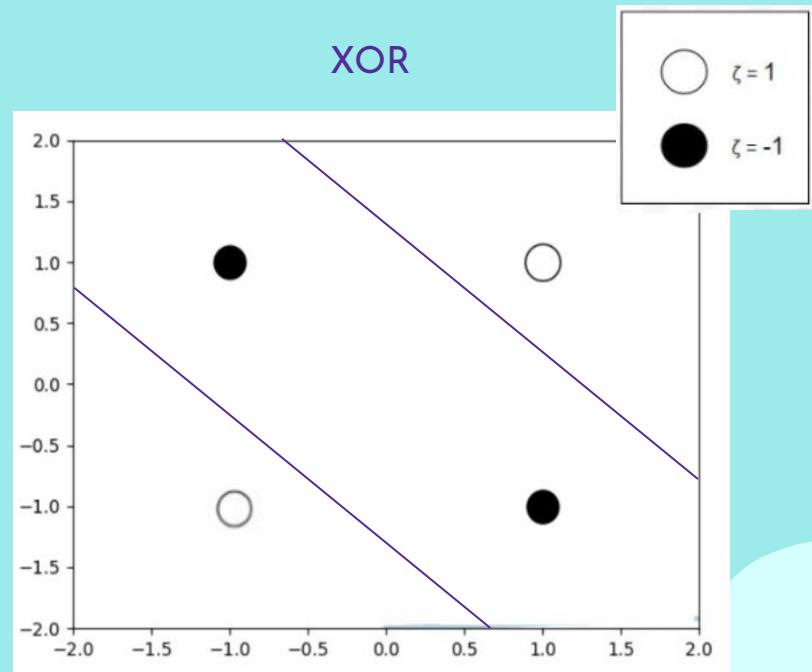
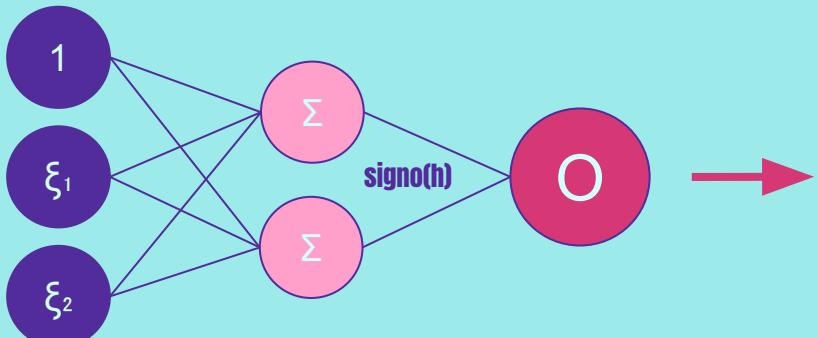
A	B	Esperado
-1	1	1
1	-1	1
1	1	-1
-1	-1	-1

Problema con Perceptrón Simple



No es linealmente separable
(una única recta no sirve para clasificar
los puntos)

Composición de funciones



Perceptron multicapa

Resultados Batch vs Online

Parámetros:

$n = 0.05$

Tamaño = [2, 1]

Epochs = 1000

Beta = 1

F = SIGN

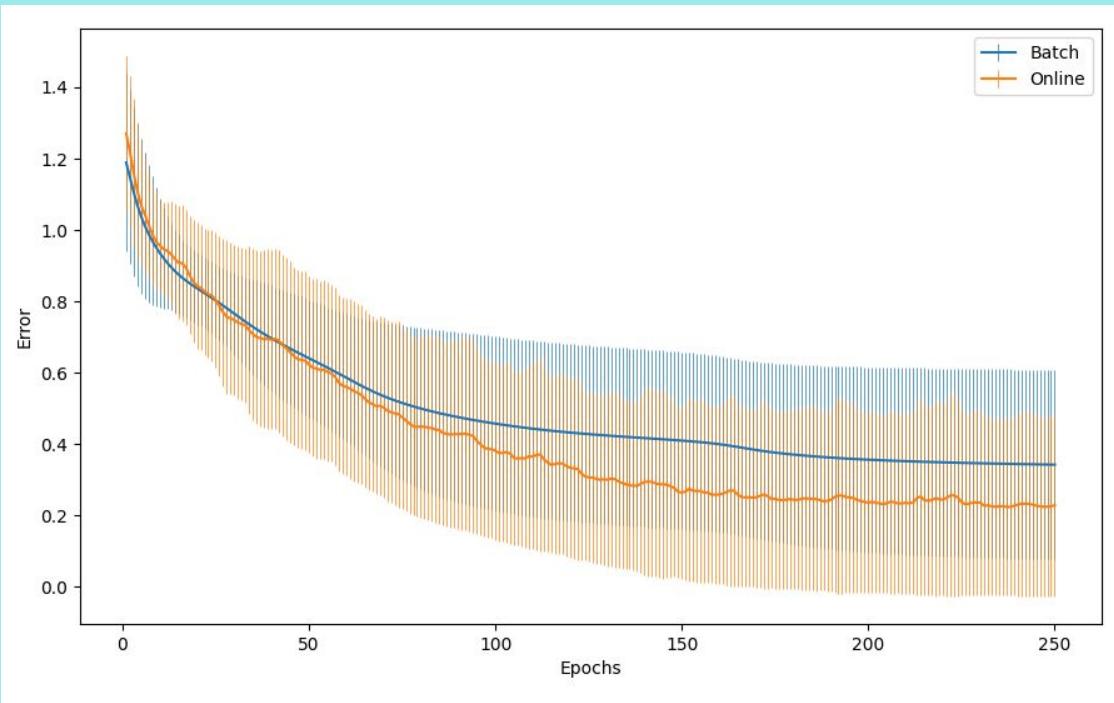
Training online

Prediction

threshold = 0.1

Sin division entre test

y train



Ejercicio 3.2 y 3.3

Definición

★ Valores de Entrada:

- ★ Dataset de 10 matrices de 5x7, representando un número.
- ★ Valores a evaluar.

★ Valores de Salida:

- ★ 3.2 → Vector con 2 valores → [0,1] par, [1,0] impar
- ★ 3.3 → Vector de 10 valores con las probabilidades de cada uno → se toma el máximo

★ Aplicación de ruido

- ★ Se itera todo el dataset aplicando de forma aleatoria entre 0 y 6 cambios en posiciones también aleatorias.
- ★ Se prueba este nuevo dataset sobre una red entrenada con el dataset original.

0	0	1	0	0
0	1	1	0	0
0	0	1	0	0
0	0	1	0	0
0	0	1	0	0
0	0	1	0	0
0	1	1	1	0

Ejercicio 3.2

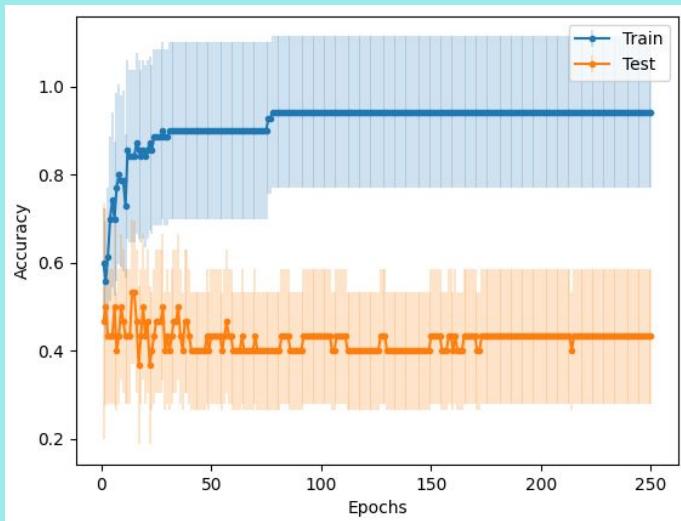
Discriminar números pares



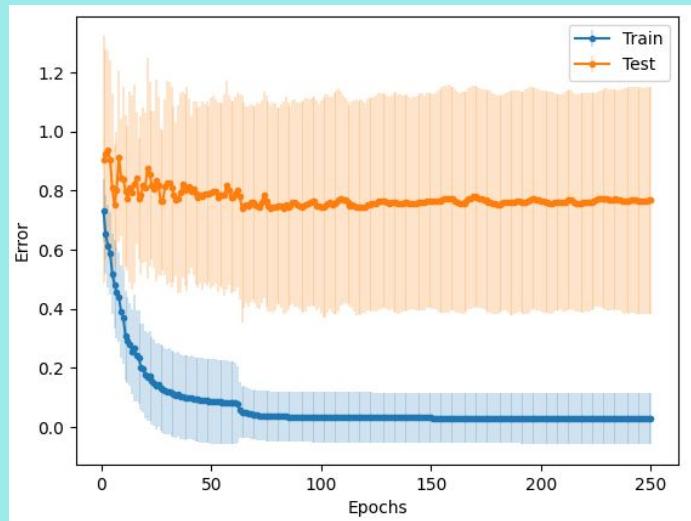
Perceptrón Multicapa

Resultados paridad

Accuracy



Error



Parámetros:

$n = 0.05$

Tamaño = [5*7, 5*7, 2]

Epochs = 250

Beta = 1

F = EXP

Training online

Porcentaje de
entrenamiento: 70%

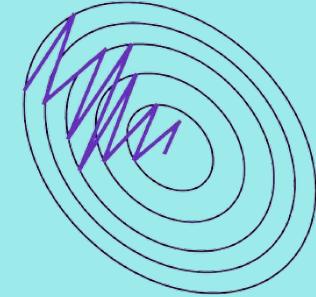
Prediction
threshold = 0.01

Momentum = 0.8

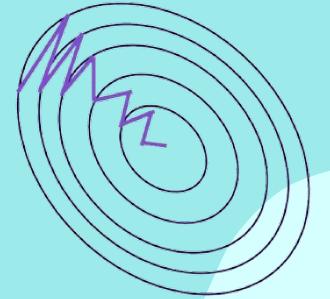
Perceptrón Multicapa

Optimización: Momentum

- ◆ Optimización sobre método Estocástico Gradiente Descendente.
- ◆ Trata de solucionar casos de oscilación o divergencia en torno a un mínimo.
- ◆ Ayuda a acelerar las gradientes de los vectores en las direcciones correspondientes.
- ◆ Provoca mayor velocidad de convergencia.
- ◆ Utiliza hiper-parámetro β entre 0 y 1.



Stochastic Gradient
Descent **without**
Momentum



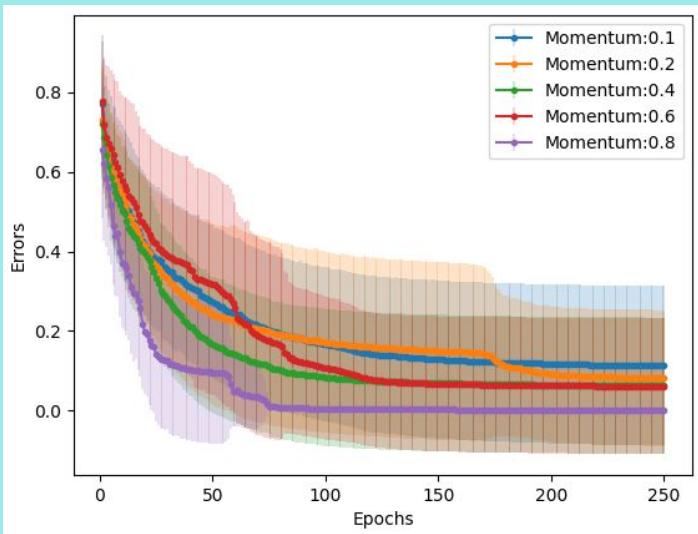
Stochastic Gradient
Descent **with**
Momentum

Perceptrón Multicapa

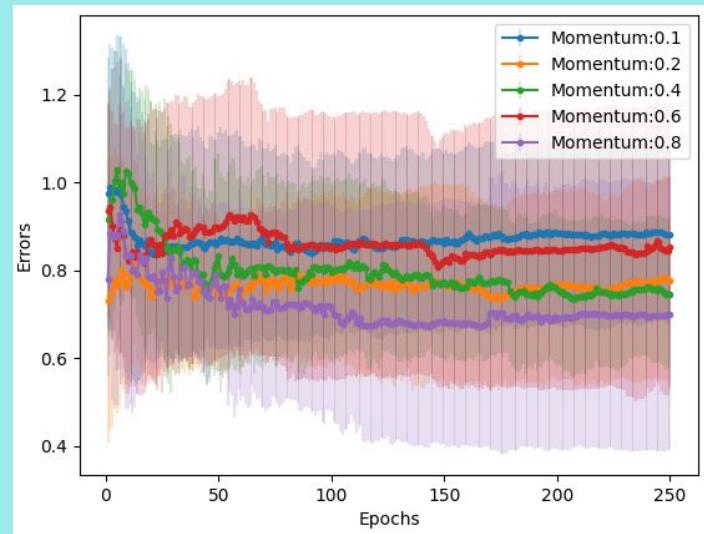
Resultados paridad

Analisis de momentum

Train error



Test error



Parámetros:

$n = 0.05$

Tamaño = [5*7, 5*7, 2]

Epochs = 250

Beta = 1

F = EXP

Training online

Porcentaje de

entrenamiento: 70%

Prediction

threshold = 0.01

Perceptrón Multicapa

Resultados paridad (con ruido)

Parámetros:

$n = 0.05$

Tamaño = [5*7, 5*7, 2]

Epochs = 250

Beta = 1

F = EXP

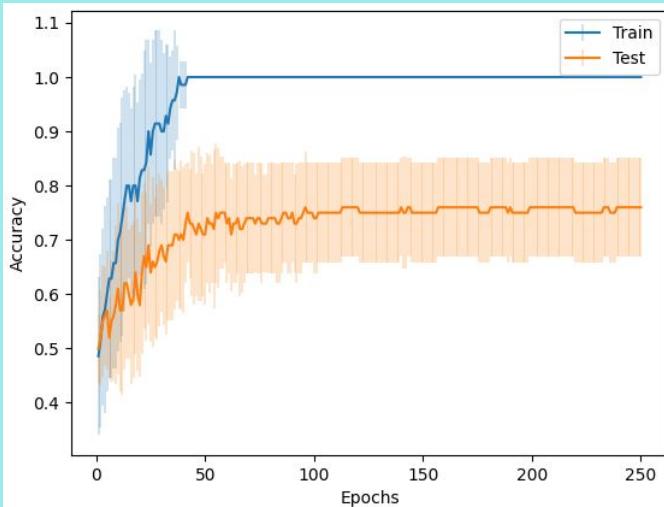
Training online

Porcentaje de entrenamiento: 70%

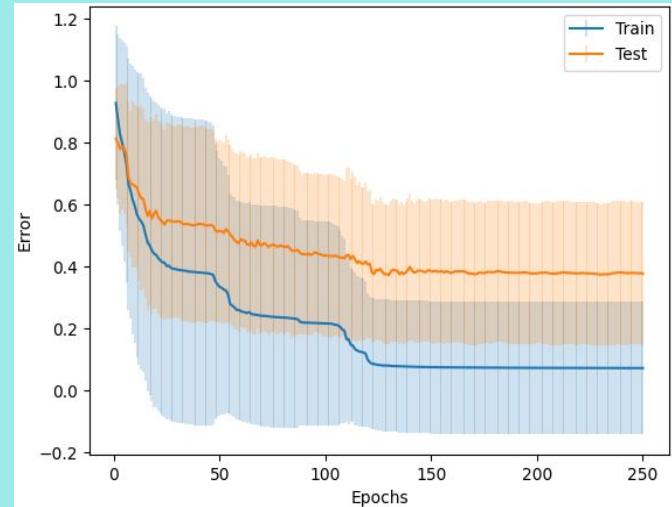
Prediction threshold = 0.01

Momentum = 0.8

Accuracy



Error



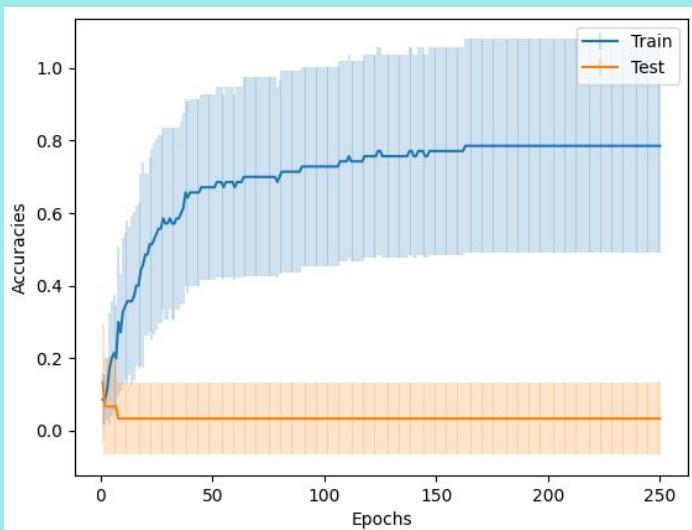
Ejercicio 3.3

Predecir dígitos

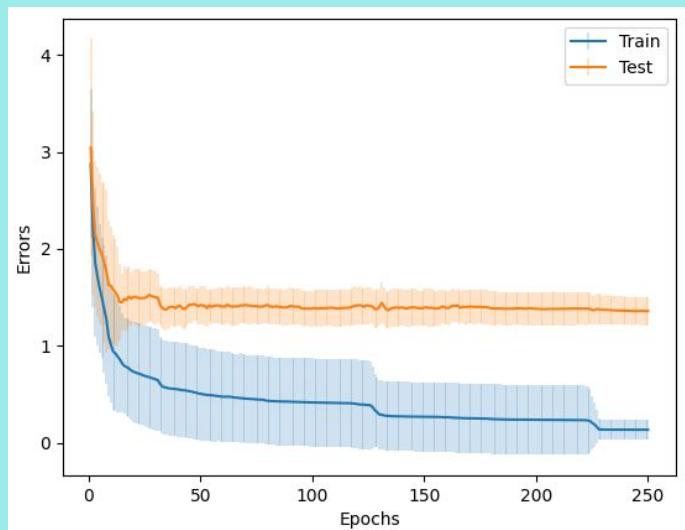
Perceptrón Multicapa

Resultados adivinar número

Accuracy



Error



Parámetros:

$n = 0.05$

Tamaño = [5*7, 5*7, 10]

Epochs = 250

Beta = 1

F = EXP

Training online

Porcentaje de
entrenamiento: 70%

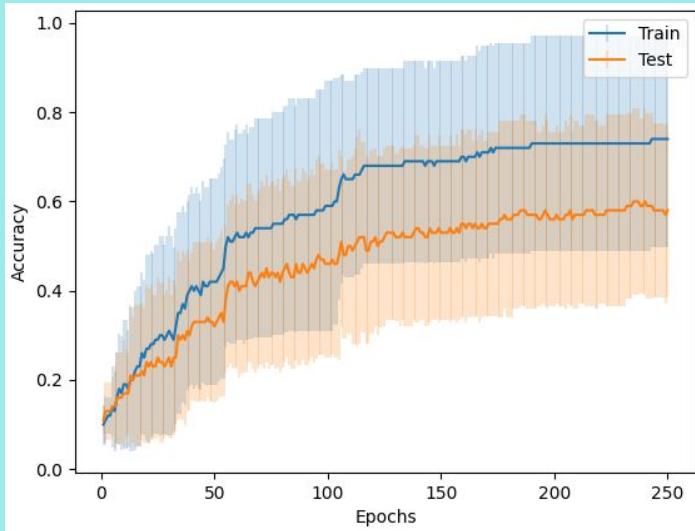
Prediction threshold = 0.01

Momentum = 0.8

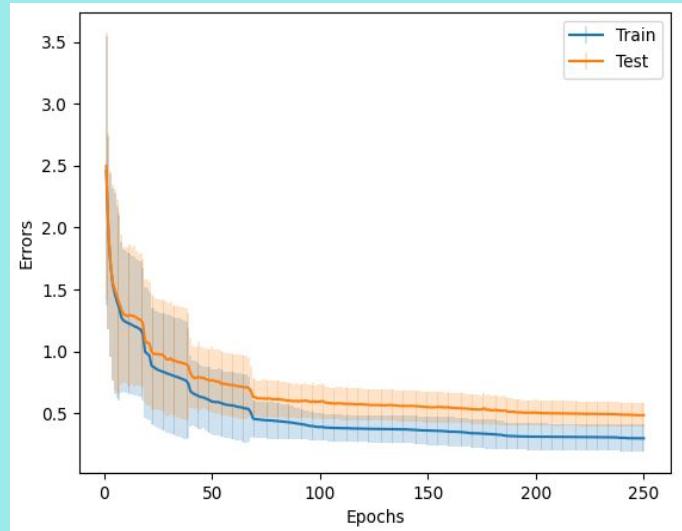
Perceptrón Multicapa

Resultados adivinar número (con ruido)

Accuracy



Error



Parámetros:

$n = 0.05$

Tamaño = [5*7, 5*7, 10]

Epochs = 250

Beta = 1

F = EXP

Training online

Porcentaje de
entrenamiento: 70%

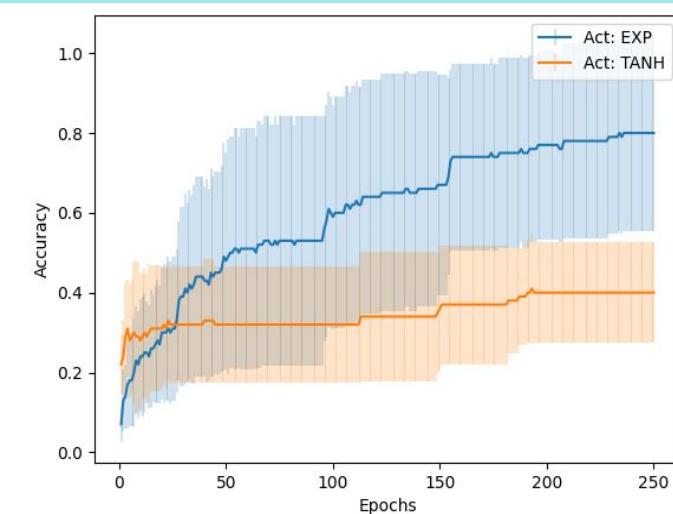
Prediction threshold = 0.01

Momentum = 0.8

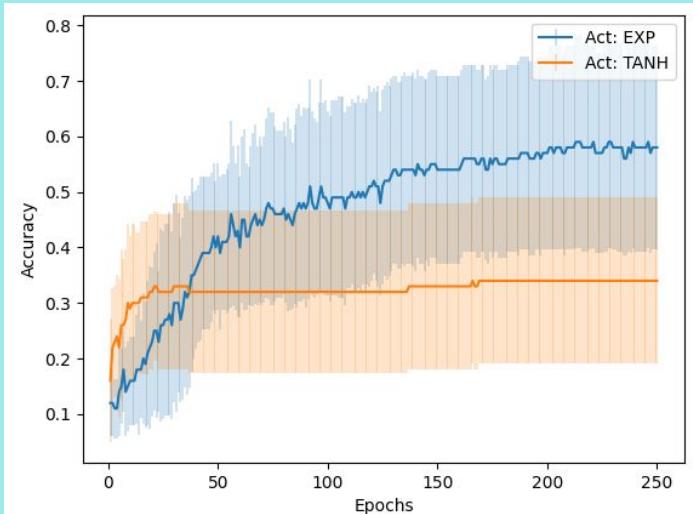
Perceptrón Multicapa

Resultados adivinar número (con ruido) variando F

Train accuracy



Test accuracy



Parámetros:

$n = 0.05$

Tamaño = [5*7, 5*7, 10]

Epochs = 250

Beta = 1

Training online

Porcentaje de
entrenamiento: 100%

Prediction threshold = 0.01

Momentum = 0.8

Ahora...
veámoslo en acción!

Conclusiones



- ☀ Existen problemas que el perceptrón simple no puede resolver, por el otro lado una red multicapa es capaz de resolver muchísimos más y con mejor precisión, pero a mayor costo de computo.
- ☀ La elección del beta depende de la función de activación y del dataset.
- ☀ Utilizar una función lineal de activación en el multicapa no tiene sentido, pues el resultado es un perceptrón ya que es una combinación lineal
- ☀ La optimización de momentum permite que la convergencia hacia los mejores resultados sea mucho más posible, mejorando el funcionamiento de la red.
- ☀ El buen funcionamiento del modelo depende de la calidad del entrenamiento. El modelo es susceptible a problemas de overfitting o underfitting que no lo generalize correctamente. Por esto, se debe buscar un dataset lo más grande y realista posible.

**¡GRACIAS!
¿PREGUNTAS?**